



Universidad Pública de Navarra
Nafarroako Unibertsitate Publikoa

Departamento de Estadística, Informática y Matemáticas

Trabajo de fin de grado

Plataforma de adquisición de datos pluviométricos para la predicción y aviso de inundaciones

Autor:

Arkaitz Oderiz Garin

Supervisor:

Unai Pérez-Goya

Pamplona, 2023

Contenidos

Lista de Figuras	iii
Lista de Tablas	iv
Lista de Códigos	vi
Lista de Teoremas	viii
Lista de Definiciones	x
Lista de Lemas	xii
1 Introducción	1
1.1 Esto es una sección	1
1.1.1 Esto es una subsección	1
2 Tecnologías	3
2.1 Lenguaje de Programación Python	3
2.1.1 Qué es Python?	3
2.1.2 Por qué Python?	3
2.2 Sistema Operativo Debian	4
2.2.1 Historia	4
2.2.2 Filosofía	4
2.2.3 Modelo de negocio	5
2.2.4 Por qué Debian?	5
2.3 Framework	7
2.3.1 Qué es un framework?	7
2.3.2 Librería vs Framework	8

2.3.3 Django	8
2.3.4 Scrappy	10
2.4 Base de Datos	13
2.4.1 Relacional vs No Relacional	13
2.4.2 PostGreSQL	13
2.4.3 Por qué PostGreSQL?	13
3 Datos	15
3.1 Aemet	15
3.2 El Agua en Navarra	16
3.3 MeteoNavarra	18
3.4 Entorno de ejecución	19
3.4.1 Preparación de entorno virtual	19
3.4.2 Instalacion y configuracion de PostGreSQL	19
4 Plataforma	21
4.1 Estructuras Planteadas	21
4.2 Flujo de Datos	22
4.2.1 Datos obtenidos	23
4.2.2 Formato de Datos	23
4.2.3 Filtrado de Datos	24
4.3 Arquitectura	24
4.3.1 Elementos presentes	25
5 Código	31
5.1 Creación de Spiders	31
5.1.1 Proceso de obtención de datos	33
5.1.2 Guardado de datos	35
5.1.3 Spider básica	35
5.1.4 Método start_requests()	36
5.1.5 Eliminar Log	37
5.2 Spiders usadas	37
5.2.1 Aemet	37
5.2.2 Chcantabrico	40
6 Conclusiones y Trabajo Futuro	47
Referencias	49
Glosario	51
Anexos	53

Lista de Figuras

2.1 Diagrama patrón MVT	8
2.2 Web Scraping (Krotov y Tennyson 2018)	11
3.1 Página Aemet de la estación en Aranguren (Navarra)	16
3.2 Página principal de aforos de El Agua en Navarra	17
3.3 Error al cargar directamente la página de datos numéricos en El Agua en Navarra	17
3.4 Apartado selección de datos MeteoNavarra	18
4.1 Idea original de la estructura de datos planteada	21
4.2 Estructura de datos usada en el proyecto	22
4.4 Estructuración básica de una Spider	25
4.3 Arquitectura de obtención y tratamiento de datos	29
5.1 Estructura del proyecto recién creado	31
5.2 Directorio de almacenamiento de las Spider	32
5.3 URL de inicio para obtener los códigos de las estaciones de Aemet	33
5.4 Inspector de webs de Chrome	34

Lista de Tablas

1.1 Mi tabla de ejemplo	1
-----------------------------------	---

Lista de Códigos

1.1	pie de código	1
5.1	Spider recién generada	32
5.2	Guardar datos	35
5.3	Configurar guardado en JSON	35
5.4	Spider de ejemplo	35
5.5	Sobre-escritura de start_request()	37
5.6	Configurar LOG	37
5.7	Code Spider	37
5.8	Data Spider	38
5.9	Code Spider	40
5.10	Nivel Spider	41
5.11	Pluviometric Spider	43
A1	Mostrar notas.	53

Lista de Teoremas

1	Teorema (Sum)	2
2	Teorema (About $C^1(0, 1)$)	2

Lista de Definiciones

1	Definición (Nice numbers)	2
---	-------------------------------------	---

Lista de Lemas

1	Lema	2
---	----------------	---

1.1 Esto es una sección

Para generar entradas en el índice de palabras. SATA.

1.1.1 Esto es una subsección

Una lista de parámetros:

- uno.
- dos.
- tres.

Una lista enumerada

1. uno.
2. dos.

Tabla 1.1: Mi tabla de ejemplo

Nombre	Medida	Otra cosa
10	10	4

Código en R del ejemplo [1.1](#):

```
1 # Establecer las credenciales de la API [1]  
2
```

```

3 library(rsat)
4 set_credentials("rsat.package", "UpnaSSG.2021")
5
6 #Definir la region
7
8 library(raster)
9 dir.create( "./RSATprueba/countries" ,recursive = TRUE)
10 spain<-getData('GADM', country= 'Spain', path=
    "./RSATprueba/countries", level=2)

```

Código 1.1: pie de código

Teorema 1 (Sum). $1 + 1 = 2$

Definición 1 (Nice numbers). *A number is nice if it looks beautiful.*

Teorema 2 (About $C^1(0,1)$). *The set $C^1(0,1)$ is interesting.*

Teoremaren erreferentzia [2](#)

Proof. To prove it by contradiction try and assume that the statemenet is false, proceed from there and at some point you will arrive to a contradiction. \square

Lema 1. *To prove it by contradiction try and assume that the statemenet is false, proceed from there and at some point you will arrive to a contradiction.*

Lemaren erreferentzia [1](#)

$$1 + e^{i\pi} = 0. \quad (1.1)$$

Formularen erreferentzia [1.1](#)

2.1 Lenguaje de Programación Python

2.1.1 Qué es Python?

Siendo su primera aparición en el año 1991 por manos de Guido van Rossum, Python es un lenguaje de programación de alto nivel interpretado que prima la legibilidad del código, siendo este a veces nominado como "seudocódigo ejecutable". [\[1\]](#)

Python a su vez es un lenguaje multiplataforma, fuertemente tipado, dinámico y multiparadigma, pues soporta programación orientada a objetos, imperativa y funcional. [\[2\]](#) [\[3\]](#)

2.1.2 Por qué Python?

La elección de Python sobre otros lenguajes se basa en su sintaxis sencilla y clara que facilita la programación, junto a la gran cantidad de librerías y frameworks potentes de los que dispone para satisfacer las necesidades que presenta este proyecto, como pueden ser la extracción de datos meteorológicos mediante web scraping y la creación de una API.

2.2 Sistema Operativo Debian

2.2.1 Historia

Conforme la computación fue tomando terreno tanto en el ámbito comercial como en el escolar, no tener una forma de instalar y configurar los sistemas de una forma rápida sin tener que partir de cero y sin tener que compilar el software necesario manualmente se convirtió en un problema patente entre los usuarios. [4] [5]

En 1993, tras varios intentos fallidos por distintas empresas de solucionar el problema, Ian Murdock, por aquel entonces estudiante de la Universidad Purdue, encontró la solución al problema basándose en el reciente proyecto de Linus Torvalds, el kernel Linux. tras el anuncio de Ian para crear un sistema operativo de forma descentralizada en paralelo como es el caso del kernel Linux, docenas de usuarios se unieron para formar el proyecto Debian Linux con la intención de crear un sistema operativo de gran calidad y mantenimiento, publicando en enero de 1994 la primera versión de Debian 0.91. [6]

2.2.2 Filosofía

Debian no intenta seguir ni competir con los líderes del sector, por el contrario, desde sus inicios el proyecto se ha basado en una filosofía centrada en la robustez y estabilidad del sistema guiada por unos estrictos estándares de calidad, actualizándose conforme las necesidades de sus usuarios a la vez que promueve el software gratuito, lo que le ha ayudado a obtener fama entre los usuarios. [7] [8]

A su vez, debido al apoyo del software libre, hace uso de múltiples licencias de software como la Licencia Pública General GNU (GPL), licencias artísticas o del tipo BSD, lo cual ha llevado al desarrollo de las Directrices de Software Libre de Debian (DFSG) con el fin de definir la construcción del software libre. [9]

Definido por estas licencias, el software libre debe cumplir al menos las que están consideradas la cuatro libertades esenciales: [10]

- Ejecutar el programa como se desee, con cualquier propósito.
- Estudiar cómo funciona el programa, y cambiarlo para que haga lo que se desee.
- Redistribuir copias para ayudar a otros.
- Distribuir copias de sus versiones modificadas a terceros permitiendo ofrecer a toda la comunidad la oportunidad de beneficiarse de las modificaciones.

2.2.3 Modelo de negocio

Todo el modelo del proyecto Debian se basa en su Contrato Social respecto a la comunidad de software libre creado en 1997, sobre el cual se estipulan las directrices a seguir para crear y distribuir software libre. [11]

No hay que confundir el termino libre, definido dentro de DFSG, con gratuito, pues un programa de software puede ser libre aunque sea de pago. Por el contrario, Debian es un proyecto libre y gratuito.

Debian se mantiene gracias a su comunidad, disponiendo más de mil desarrolladores y contribuidores por todo el mundo aportando al proyecto con su tiempo y conocimiento de forma gratuita. Esto, junto a la asistencia de múltiples empresas que dan soporte a Debian dentro del proyecto de socios [12] y el sistema de donaciones [13] usado para hardware, dominios, certificados criptográficos, conferencias, etc han ayudado en el éxito y crecimiento del proyecto dentro de su filosofía.

2.2.4 Por qué Debian?

El mercado está repleto de distintas posibles alternativas a Debian, ya sean de pago, Windows Server OS o Red Hat Enterprise Linux (RHEL), gratuitos, Ubuntu Server y Fedora Server, o incluso en la nube, Amazon Web Services (AWS), Google's Cloud Platform.

Descartando todo sistema de pago, aunque las posibilidades se reducen aun hay múltiples opciones sobre las que elegir, pero son pocas las que ofrecen la misma usabilidad que Debian con sus más de 59000 paquetes en su versión estable o incluso puedes usar las versiones «en pruebas» o «inestable» en caso de querer probar las nuevas funciones antes de su lanzamiento oficial. [14]

Aunque todos los sistemas basados en Linux disponen de las mismas características,

siendo software libre y gratuito con soporte multi-usuario, multi-proceso y uso en tiempo real, Debian siendo uno de los sistemas más longevos del mercado a tomado fama entre la competencia por su seguridad y estabilidad. Siendo la base para muchas de las distribuciones más populares contra las que compite, como Ubuntu, Knoppix, PureOS o Tails.

Cabe mencionar, que parte de esta seguridad y estabilidad puede llegar a ser un limitante a la hora de elegir Debian como sistema operativo dependiendo de tus necesidades a nivel de uso pues el software compatible igual no es la versión más reciente.

Finalmente, una característica distintiva de Debian frente a la competencia gratuita es su compatibilidad con un uso 24/7, pues otras alternativas gratuitas o no dan soporte a esta característica, Fedora Server o, necesitas disponer de una licencia de pago como es el caso de Ubuntu Server mediante Ubuntu Pro.

Una vez contado todo esto, puesto que no me afecta negativamente el no disponer de las versiones más recientes de software y necesito de un sistema 24/7 gratuito, parece lógica la elección de Debian como sistema operativo para usar en el servidor.

2.3 Framework

2.3.1 Qué es un framework?

Un framework es software que provee una infraestructura básica sobre la que desarrollar tus proyectos, aportando las funcionalidades y estructuras básicas necesarias para este sin la necesidad de programar todo desde cero, ahorrando tiempo de desarrollo y aportando robustez al proyecto. [15]

Cada framework aportará su propia colección de módulos y paquetes específicos para ayudar en el desarrollo, es por esto que generalmente se clasifican en tres clases distintas según funcionalidades. [16]

Tipos de frameworks

Full Stack

Un framework full-stack es apto tanto para desarrollo back-end como front-end, aportando todas las herramientas posibles que ayuden con el desarrollo gráfico de la interfaz de usuario (UI), gestión de bases de datos, protocolos de seguridad y lógica de negocio entre tantos. Siendo Django un ejemplo de framework full-stack.

Micro

Los framework micro son ligeros por definición, siendo en cierta medida lo contrario de un framework full-stack, pues aunque los componentes que aportan como puede ser la gestión de bases de datos son los mismos, estos no vienen incluidos de forma nativa. Esto se debe a que buscan aportar flexibilidad y libertad a los desarrolladores para que incluyan únicamente aquellas herramientas que necesiten.

Como se explica en la documentación de Flask, uno de los framework tipo micro más relevante, el 'micro' de microframework significa que el núcleo del framework es simple pero extensible.

Asíncrono

Estos framework están dirigidos por eventos. en vez de hacer un manejo operacional línea a línea de las funciones en la que se van ejecutando una detrás de otra, el código asíncrono no es bloqueante por lo que no se espera que un evento termine para ejecutar el siguiente, ejecutándolo de forma simultánea. Debido a esto un framework asíncrono puede llegar a conseguir un gran rendimiento si se usa en un servidor que lo permita.

2.3.2 Librería vs Framework

Aunque ambas ofrecen funcionalidades operacionales, su mayor diferencia radica en la especificidad y complejidad de estas.

Las librerías están compuestas por múltiples métodos para un uso específico sin aportar mucha complejidad, realizando una tarea por función.

Por el contrario, como los framework tienen en cuenta las posibles necesidades de tu proyecto, pudiéndose permitir ser aún más específicos, ofreciendo la arquitectura y comportamiento básico de la aplicación, dejando la flexibilidad de desarrollar las funcionalidades necesarias para su funcionamiento, aportando herramientas sobre las que trabajar. [17]

2.3.3 Django

Qué es Django?

Django es un framework web de tipo full-stack gratuito y de código abierto para Python. Sigue el principio DRY "Don't Repeat Yourself" por lo que se enfoca en el menor uso de código, el desarrollo rápido y la reutilización de componentes. [18] [19]

Hace uso de su auto denominado patrón Modelo-Vista-Template (MVT) 2.1 una variante del conocido Modelo-Vista-Controlador (MVC). [20]




Figura 2.1: Diagrama patrón MVT ¹

Para poder trabajar con bases de datos relacionales tales como, Oracle, MySQL y PostgreSQL, Django usa un Mapeador Relacional de Objetos (ORM) permitiendo interactuar con ellas mediante SQL.

¹<https://docs.hektorprofe.net/django/web-personal/patron-mvt-modelo-vista-template/>

Por qué Django?

Partiendo de que el lenguaje de programación a usar es Python, Django es uno de los frameworks más reputados dirigidos a este lenguaje, teniendo en cuenta su naturaleza gratuita y de código abierto. Siendo usado tanto por la comunidad como por empresas tales como Instagram, Mozilla y Facebook. Aunque no por ello significa que no disponga de poca competencia, siendo TurboGears, web2py, Bottle y Flask de las más notables.

El que sea un framework full-stack no va a aportar la flexibilidad, libertad y ligereza que da el uso de un microframework, sobre todo a la hora de agregar únicamente aquellas herramientas que considere necesarias, pero si que atenuará la carga de trabajo que puede suponer un microframework si no se dispone de la experiencia necesaria para usarlo.

Otra característica por la que me he decantado por Django, aunque no sea única de él, es su compatibilidad con bases de datos relacionales de forma nativa, cosa que facilitara el uso de estas en el proyecto.

2.3.4 Scrapy

Qué es el Web Scraping?

Web scraping, también conocido como web extraction o web harvesting, es una técnica de extracción de datos desestructurados de la World Wide web (WWW) y guardarlos de forma estructurada en una base de datos o en un sistema de ficheros en formato XML, JSON o CSV para su posterior recuperación o análisis. Generalmente, los datos web son adquiridos mediante el uso de Hyper-text Transfer Protocol (HTTP) o a través de un navegador web, ya sea de forma manual o automática mediante web crawlers, herramientas diseñadas con este propósito, siendo capaces de convertir páginas web enteras en información bien estructurada. [21] [22]

Debido a la gran cantidad de datos que son generados constantemente en la WWW, web scraping es considerado una forma eficiente y poderosa de amasar big data.


Web scraping puede ser usado en una gran variedad de entornos, como la recolección de comentarios en redes sociales, listado de la propiedad inmobiliaria o en este caso el monitoreo y comparación de los niveles de los ríos y datos pluviométricos.

Procedimiento básico en Web Scraping

El proceso de recolección de datos de Internet se puede dividir en tres procesos secuenciales, el estudio de la pagina sobre la que trabajar, adquirir los recursos web y, luego, organizar la información deseada. 2.2

El primer paso consiste en mirar la estructuración de la web para seleccionar aquellos datos que queramos extraer, comprobando los recursos HTML, CSS y viendo si hace uso de JavaScript. Para realizar el segundo paso de adquisición de los recursos, el proceso empieza con los programas de web scraping enviando un request, ya sea mediante GET o POST, a la página web deseada. Una vez el request sea recibido y procesado por la web, esta enviará los recursos solicitados al programa. Después, pasaríamos al tercer paso, en el que analizaríamos los recursos obtenidos y los filtraríamos de tal forma que nos quedásemos únicamente con la información que nos sea necesaria. Finalmente almacenaríamos la información obtenida para su posterior análisis.

²https://www.researchgate.net/figure/Web-Scraping-Adapted-from-Krotov-and-Tennyson-2018_fig1_324907302

Figura 2.2: Web Scraping ²

Qué es Scrapy?

Scrapy es un framework asíncrono para web crawling y web scraping gratuito y de código abierto. Por defecto proporciona todas las herramientas necesarias para realizar la tarea de extracción, procesamiento y estructuración de los datos adquiridos, además de dar la opción de extender funcionalidades en caso necesario, haciéndolo extremadamente versátil. [23]

Pensado para navegar entre webs y extraer información de forma estructurada de ellas, Scrapy es usado para múltiples propósitos, por ejemplo, el minado de datos o la monitorización y análisis de datos.

Por qué Scrapy?

A la hora de buscar herramientas para web scraping en Python obtuve tres alternativas principales, BeautifulSoup, Selenium y Scrapy.

La primera es una librería de parseo de HTML y XML, que, aunque podría haberme servido para mi propósito inicialmente, a la larga su sencillez hubiera sido más un problema que una ayuda.

La segunda por el contrario, no es una herramienta para hacer web scraping como tal y se centra en la automatización de la navegación web como entorno de pruebas. Debido a esto, no es una herramienta que haya usado para el web scraping, pero sí que ha sido usada junto con Scrapy para navegar entre webs y sacar los datos de estas.

Scrapy fue elegida gracias a la flexibilidad y versatilidad que proporciona a la hora de trabajar, pudiendo crear proyectos sencillos en cuestión de minutos con las herramientas base proporcionadas o investigar como trabajar con estas herramientas y crear proyectos complejos que satisfagan tus necesidades de la manera que desees.

Esto implica que la curva de aprendizaje de Scrapy sea mayor que la que puede tener BeautifulSoup sobre todo al inicio, llegando a parecer abrumador. A su vez, Scrapy tiene el mejor rendimiento entre las tres. [17]

Finalmente, cabe mencionar que Scrapy no dispone de rotación de IP, renderizado JavaScript, ni geolocalización como pueden tener las alternativas de pago, cosa que no es un impedimento para llevar a cabo el proyecto.

2.4 Base de Datos

2.4.1 Relacional vs No Relacional

2.4.2 PostGreSQL

2.4.3 Por qué PostGreSQL?

Para este proyecto disponemos de los siguientes datos obtenidos de distintas páginas web:

- Nivel (m)
- Caudal (m^3/s)
- Precipitación (mm)
- Temperatura ($^{\circ}C$)
- Humedad (%)
- Radiación (W/m^2)

A su vez, dispondremos de la fecha y hora en la que se hicieron la lectura de los datos, junto con los códigos y coordenadas de las estaciones sobre las cuales obtenemos los datos.

3.1 Aemet

La Agencia Estatal de Meteorología (AEMET) es el Servicio Meteorológico Nacional y Autoridad Meteorológica del Estado, siendo su objetivo es la monitorización y predicción de fenómenos meteorológicos.

AEMET dispone de una API de obtención de datos llamada AEMET OpenData la cual no usaremos pues muchos de los datos que se obtienen de esta manera no nos son útiles.

Como se ve en la imagen [3.1](#), dentro de la web podemos encontrar de forma accesible

múltiples datos relacionados con la meteorología tomados cada hora, de los cuales seleccionaremos únicamente temperatura, precipitación y humedad, puesto que los datos relacionados con el viento o la presión atmosférica no son tan relevantes para este proyecto.

Actualizado: martes, 09 mayo 2023 a las 16:22 hora oficial
 Ind. climatológico: 9263X - Altitud (m): 572
 Latitud: 42° 46' 34" N - Longitud: 1° 31' 57" O - Posición: Ver localización
 Municipio: Aranguren (Navarra) - Ver predicción

Exportar a excel Exportar a csv

Fecha y hora oficial	Temp. (°C)	V. vien. (km/h)	Dir. viento	Racha (km/h)	Dir. racha	Prec. (mm)	Presión (hPa)	Tend. (hPa)	Humedad (%)
09/05/2023 16:00	14.6	5	→	18	↘	0.0			88.0
09/05/2023 15:00	14.6	8	→	15	↘	0.4			89.0
09/05/2023 14:00	14.0	4	→	18	→	0.2			88.0
09/05/2023 13:00	13.7	9	→	26	↘	0.0			85.0
09/05/2023 12:00	13.7	6	↗	11	↑	0.0			73.0
09/05/2023 11:00	13.9	3	↑	6	↗	0.0			69.0
09/05/2023 10:00	14.0	0	-	4	→	0.0			66.0
09/05/2023 09:00	13.3	0	-	3	↙	0.0			69.0
09/05/2023 08:00	10.5	0	-	10	↙	0.0			80.0
09/05/2023 07:00	8.8	5	↙	9	↙	0.0			76.0
09/05/2023 06:00	8.7	7	↙	9	↙	0.0			77.0
09/05/2023 05:00	9.0	3	←	8	↙	0.0			85.0
09/05/2023 04:00	9.1	4	↙	8	↙	0.0			84.0
09/05/2023 03:00	9.3	5	↙	9	↙	0.0			83.0
09/05/2023 02:00	10.2	2	↓	9	↙	0.0			78.0
09/05/2023 01:00	10.5	3	↙	10	↙	0.0			81.0
09/05/2023 00:00	11.2	5	↙	8	↙	0.0			84.0
08/05/2023 23:00	12.2	4	↙	10	↙	0.0			81.0
08/05/2023 22:00	14.0	0	-	9	↖	0.0			73.0
08/05/2023 21:00	16.8	4	↓	10	↘	0.0			60.0
08/05/2023 20:00	19.2	6	↘	23	↘	0.0			48.0
08/05/2023 19:00	20.4	12	↘	27	→	0.0			40.0
08/05/2023 18:00	22.1	16	→	31	→	0.0			36.0
08/05/2023 17:00	22.1	16	→	34	→	0.0			37.0

Lineas por página 50 Página 1 de 1

Figura 3.1: Página Aemet

3.2 El Agua en Navarra

En esta página encontraremos los datos tanto del nivel de los ríos como de su caudal en los últimos 15 días en periodos de 10 minutos, siendo una de las fuentes principales de datos.

La sección de aforos en la página 3.2 muestra un mapa de Navarra y esta estructurada en 6 regiones, Norte, Arga, Ega, Ebro alto, Ebro bajo y Aragón, accediendo a cada región nos aparece el mapa de la región dándonos acceso a todas las estaciones en la zona.

Una vez dentro de la estación tendremos la posibilidad de observar los datos, primeramente en forma de gráfica y en caso de quererlo en forma numérica, pero no se puede acceder a los datos numéricos sin antes haber visitado la versión gráfica 3.3.

Debido a este problema, para la obtención de los datos primero cargamos la web gráfica y le pasamos un script JavaScript para pulsar el botón que finalmente nos da acceso a los datos deseados.

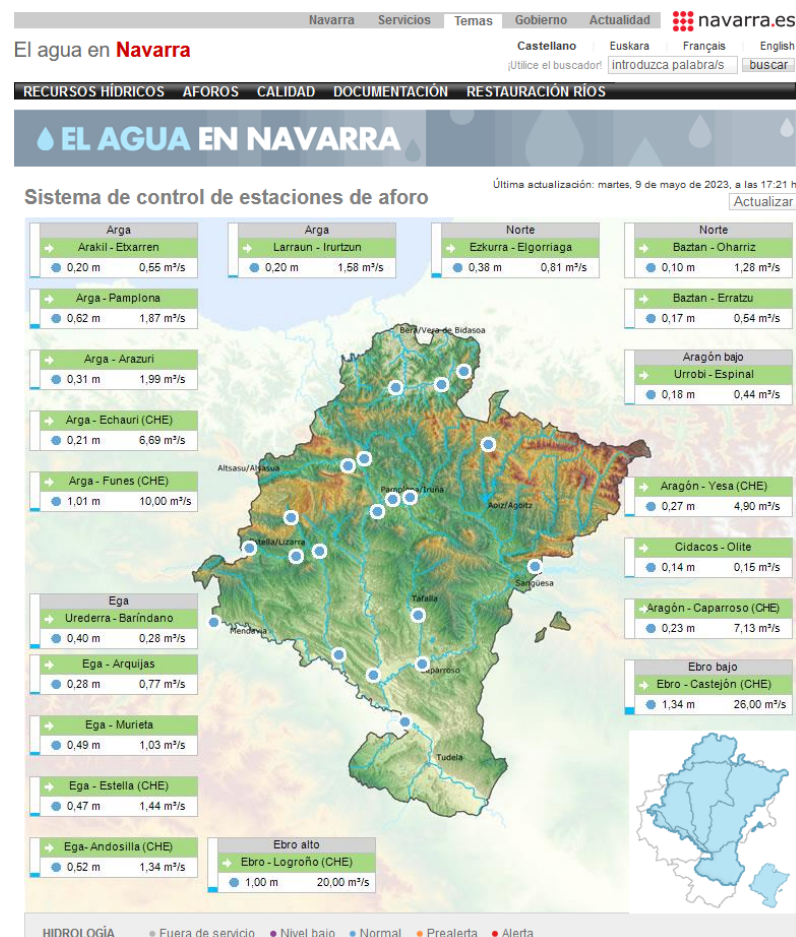


Figura 3.2: Página El Agua en Navarra



Figura 3.3: Error datos numéricos en El Agua en Navarra

3.3 MeteoNavarra

En la página de meteorología y climatología de Navarra encontramos una gran sección de estaciones de las cuales poder obtener datos.

De entre los dos tipos de estaciones disponibles, automática y manual, únicamente tomamos los datos de las estaciones automáticas, esto se debe a que las manuales solo proveen datos diarios de la temperatura máxima, mínima y de la precipitación acumulada. Esto hace que no dispongamos de ningún dato hasta que finalice el día, cosa que no es viable si lo que se propone es predecir cambios radicales en un periodo de tiempo reducido.

Las estaciones automáticas proporcionan tanto datos en periodos de diez minutos como datos diarios, siguiendo el mismo razonamiento que con las estaciones manuales no tomamos los datos diarios y, entre los actualizados cada diez minutos tomamos la temperatura, humedad relativa, radiación global y precipitación en un periodo de dos días.

1. Parámetros

Parámetros 10 minutos

- ☒ Temperatura
- ☒ Humedad relativa
- ☒ Radiación global
- ☐ Insolación
- ☒ Precipitación
- ☐ Velocidad viento 10 m
- ☐ Dirección viento 10 m
- ☐ Velocidad racha máxima 10 m
- ☐ Dirección racha máxima 10 m
- ☐ Velocidad viento 2 m
- ☐ Dirección viento 2 m
- ☐ Velocidad racha máxima 2 m
- ☐ Dirección racha máxima 2 m
- ☐ Desviación dirección viento 10 m
- ☐ Desviación dirección viento 2 m
- ☐ Desviación velocidad 10 m
- ☐ Desviación velocidad 2 m
- ☐ Humectación hoja (resistencia)
- ☐ Radiación Solar PAR acumulada 10min
- ☐ Temperatura suelo

Datos en **horario solar**.

2. Fechas

hoy **ayer**

Desde

Hasta (excluido)

Parámetros Diarios

- ☐ Temperatura media
- ☐ Temperatura máxima
- ☐ Temperatura mínima
- ☐ Humedad relativa med.
- ☐ Humedad relativa máx.
- ☐ Humedad relativa mín.
- ☐ Precipitación acumulada
- ☐ Radiación global
- ☐ Insolación total
- ☐ Velocidad media viento 10 m
- ☐ Dirección viento 10 m (MODA)
- ☐ Velocidad racha máx 10 m
- ☐ Dirección racha máx 10 m
- ☐ Velocidad media viento 2 m
- ☐ Dirección viento 2 m (MODA)
- ☐ Velocidad racha máx 2 m
- ☐ Dirección racha máx 2 m
- ☐ Radiación PAR diaria acumulada
- ☐ Temperatura media suelo

Figura 3.4: Datos MeteoNavarra

3.4 Entorno de ejecución

El proyecto se dividirá en dos ordenadores (maquinas virtuales). Uno de ellos será el responsable de la base de datos en PostgreSQL, mientras que, el otro, se encargara de la ejecución del código de obtención de datos, tratarlos y enviarlos a la base de datos.

3.4.1 Preparación de entorno virtual

Primero instalaremos las dependencias para crear y activar un entorno virtual sobre el que trabajar, para ello ejecutaremos los siguientes comandos:

```
#Instalamos las dependencias
user@host:~$ sudo apt install python3-venv python3-dev

#Creamos un nuevo directorio sobre el que trabajar
user@host:~$ mkdir ~/dirdemiproyecto
user@host:~$ cd ~/dirdemiproyecto

#Creamos el entorno virtual
user@host:~/dirdemiproyecto$ python3 -m venv envdemiproyecto

#Activamos el entorno virtual
user@host:~/dirdemiproyecto$ source envdemiproyecto/bin/activate

#Una vez seguidos los pasos nuestra terminal debe mostrarse así
(envdemiproyecto) user@host:~/dirdemiproyecto$
```

Cada Spider dispondrá de su propio entorno virtual, nombrado tras la pagina web a la que representa, de esta forma, por ejemplo, el entorno virtual para la web de chcantabrico también se llamará chcantabrico. Otro entorno virtual sera usado para el servidor Django y los Scripts encargados del envío de datos.

3.4.2 Instalacion y configuracion de PostgreSQL

Comenzamos con los comandos necesarios para la instalación inicial de PostgreSQL y con la creación de un usuario y una base de datos.

```
#Instalamos PostgreSQL y las dependencias
user@host:~$ sudo apt install libpq-dev postgresql postgresql-contrib

#Iniciamos sesion usando el role postgres y accedemos a PostgreSQL
user@host:~$ sudo -u postgres psql
```

```
#Si todo esta bien la terminal deberia mostrarse así
postgres=#
```

```
#Creamos un nuevo usuario
```

```
postgres=# CREATE USER miusuario WITH PASSWORD 'micontraseña';
```

```
#Configuramos varios parametros del usuario para una mejor integracion con Django
```

```
postgres=# ALTER ROLE miusuario SET client_encoding TO 'utf8';
```

```
postgres=# ALTER ROLE miusuario SET default_transaction_isolation TO 'read committed';
```

```
postgres=# ALTER ROLE miusuario SET timezone TO 'UTC';
```

```
#Creamos la Base de Datos
```

```
postgres=# CREATE DATABASE bbddmiproyecto;
```

```
#Otorgamos permisos de administrador a nuestro usuario en la base de datos
```

```
postgres=# GRANT ALL PRIVILEGES ON DATABASE bbddmiproyecto TO miusuario;
```

```
#Una vez finalizado
```

```
postgres=# \q
```

En este punto ya tendríamos de una base de datos y de un usuario con el que conectarnos a esta desde Django.

Ahora quedaría configurar el permiso de comunicación entre dispositivos, más concretamente la conexión remota de Django con PostgreSQL.

4.1 Estructuras Planteadas




Figura 4.1: Estructura descartada

Problema: aunque sea la estructura más simple y fácil de implementar, pues scrapy mismo puede insertar los datos scrapeados de las web de forma directa en PostGreSQL, Django hace uso de un sistema de gestión de versiones de los cambios realizados en la BBDD con el fin de reducir la carga de peticiones a la BBDD, esto se aplica desde el lado de Django, lo que supondría un problema a la hora de insertar datos directamente de Scrapy a PostGreSQL, pues los nuevos datos podrían no llegar

a ser detectados por Django, generando la situación de que una vez se vayan a pedir los nuevos datos Django no devuelva nada pues desde su punto de vista los datos que ya dispongo son la versión mas reciente, luego no es necesario realizar llamada alguna a la BBDD.

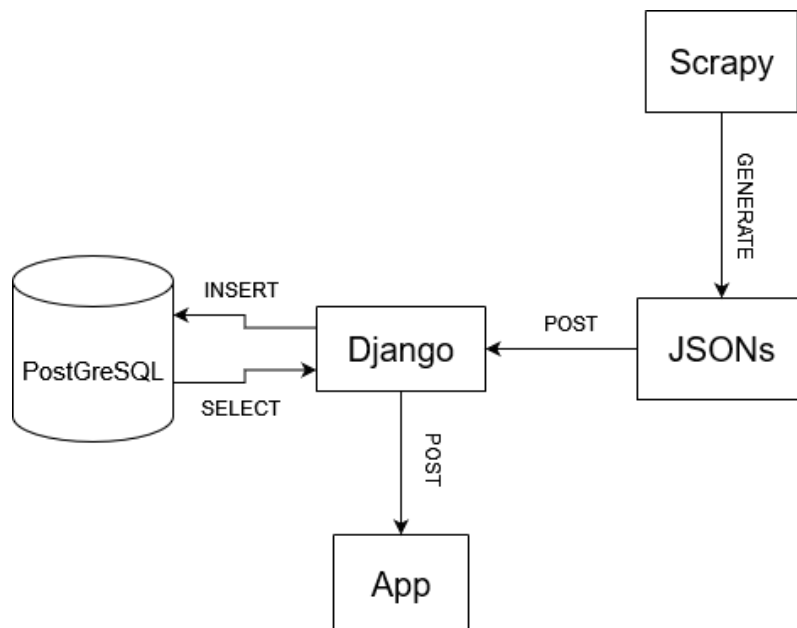


Figura 4.2: Estructura usada

Solución: Pasa solventar el problema hemos incluido un paso intermedio en el que inicialmente almacenamos los datos obtenidos de las distintas webs en formato JSON, para posteriormente enviárselos a Django, el cual se encargara de subir los datos a la BBDD, mientras, el resto de la arquitectura seria idéntico a la versión original.

4.2 Flujo de Datos

- 1.- Pedir datos (JSON1)
- 2.- Formatear datos en un nuevo JSON (JSON1 -> JSON2)
- 3.- Mandar datos a la BBDD (JSON2)
- 4.- Marcar JSON como old (JSON2 -> JSON3)
- 5.- Borrar JSON original (JSON1)

While(true)

- 1.- Pedir datos (JSON1)

- 2.- Formatear datos en un nuevo JSON (JSON1 -> JSON2)
- 6.- Crear JSON con las nuevas fechas (JSON2 != JSON3 y fecha de hoy -> JSON4)
- 7.- Mandar datos a la BBDD (JSON4)
- 4.- Marcar JSON como old (JSON2 -> JSON3)
- 5.- Borrar JSON original (JSON1)
- 8.- Borrar JSON viejo (JSON3)
- 9.- Borrar JSON diferencias (JSON4)

Puesto que los datos obtenidos no son los mismos para cada web, antes de ser enviados a Django deben ser parseados para compartir una estructura heterogénea, una vez obtenido el JSON parseado, en caso de ser la primera iteración se mandaran directamente los datos a la BBDD, de no ser la primera iteración, se tomaran unicamente los nuevos datos obtenidos como datos a enviar, una vez enviados los datos el JSON parseado sera marcado como old (viejo) para ser el punto de comparación respecto a los datos mas recientes que obtendremos de las webs.

4.2.1 Datos obtenidos

Aemet:

temperatura, humedad, precipitación

meteoNavarra:

temperatura, humedad, precipitación, radiación

aguaEnNavarra:

nivel, caudal

chcantabrico:

nivel, precipitación, seguimiento, alerta, pre-alerta

En todas las webs se proporciona las coordenadas junto con la fecha y hora en la que se ha hecho la medida

4.2.2 Formato de Datos

No todas las webs presentan sus datos de la misma manera, es por eso que nos encontramos con que los datos que hemos obtenido pueden llegar a estar repartidos en distintas páginas, haciendo necesario el uso de múltiples spiders, resultando en multiples JSON.

Es por eso que para cada web se ha creado una función para parsear (formatear) los datos obtenidos, de esta manera disponemos de una estructura única para los datos

recibidos, haciendo su uso posterior más fácil, ya sea a la hora de tratarlos posteriormente como para almacenarlos en la base de datos.

Esquema obtenido:

```
1  [
2  {
3    "coordenadas": "X. 598270,3 | Y. 4659333 | Z. 37928",
4    "estacion": "64",
5    "datos": [
6      {
7        "fecha y hora": "01/06/2023 11:20:00",
8        "temperatura (C)": null,
9        "humedad (%)": null,
10       "precipitacion (mm)": null,
11       "nivel (m)": "0,05",
12       "caudal (m^3/s)": null,
13       "radiacion (W/m^2)": null
14     }
15   ]
16 }
17 ]
```

4.2.3 Filtrado de Datos

Una vez formateados los datos con el fin de reducir la carga a la base de datos, estos son filtrados mediante la comparación con los ficheros anteriormente marcados como old, de esta forma nos aseguramos de mandar a la base de datos unicamente las instancias nuevas de los datos recogidos, pues no disponemos de ninguna forma para filtrar los datos a la hora de obtenerlos. Estos datos serán guardados en un tercer JSON.

4.3 Arquitectura

Para poder realizar el trabajo se ha diseñado la siguiente arquitectura.[4.3](#)

4.3.1 Elementos presentes

Entornos virtuales

Con el fin de que la plataforma sea lo mas fácilmente ampliable se ha decidido que cada Spider disponga de su propio entorno virtual, esto permite añadir dependencias de tal forma que no afecten a el resto de los Scripts presentes, ayudando en la encapsulación de dependencias.

El mayor inconveniente de una plataforma así es la redundancia de código, al ser múltiples entornos independientes es necesario que mucho código sea repetido en cada uno de ellos, cosa que si fuera un único entorno en el que se ejecutara todo, con una clase sobre la que heredar y o una interfaz, seria mucho el código que nos ahorraríamos.

Actualmente la plataforma dispone de cuatro entornos virtuales para cada Spider y un entorno virtual sobre el que ejecutar el servidor de Django.

Spiders

Cada Spider representa una web, de tal forma que cada una de ellas obtiene los datos de la web sobre la que se ha diseñado exclusivamente, para poder realizar esta tarea por cada web han sido necesarias varias Spider, aunque de forma simplificada se pueden agrupar por, aquellas que obtienen las estaciones junto con sus códigos y, las de obtención de datos.

De esta forma dividimos las tareas dándonos la posibilidad de ejecutar aquella que mejor nos venga en cada momento.

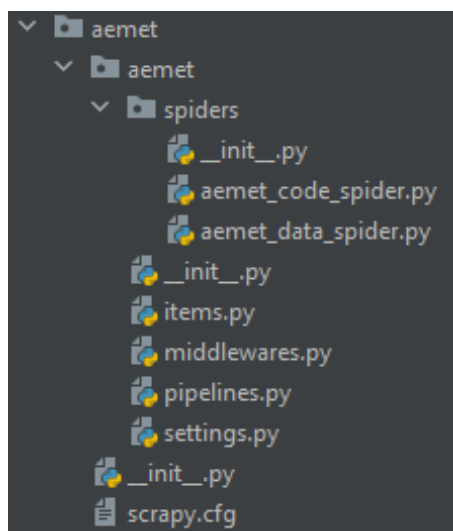


Figura 4.4: Estructuración básica de una Spider

Runners

Runner es la forma en la que han sido nombrados los Scripts cuya función es posibilitar la ejecución en nuestro caso asíncrona de una o múltiples Spiders mediante un único comando.

Es un Script simple en el que una vez dispones de la estructura básica en caso de necesitar añadir o eliminar una Spider solo tienes que agregar o eliminar la Spider en cuestión y ya estaría listo.

A su vez, al añadir un intermediario el comando de ejecución pasa de ser, scrapy crawl nombreSpider por cada Spider que se desea ejecutar, a, python nombreRunner.py facilitando la automatización de ejecución de las Spider.

Executers

Aumentado un poco mas la abstracción nos encontramos con los Executers, Scripts en Bash encargados de activar el entorno virtual de la Spider deseada y acto seguido ejecutar su respectivo Runner. Estos existen (en mayor medida que los Runners) con el fin de ayudar con el mantenimiento de la arquitectura, creando un nuevo intermediario en la cadena de ejecución.

Están diseñados de tal forma que funcionen pasandoles un único argumento representando la web de la que quieres obtener los datos, haciendo que la agregación de nuevas Spiders junto con sus entornos sea tan sencillo como respetar las rutas y nombres predefinidos.

JSONs

Este apartado es un conjunto de directorios en los que se van almacenando los JSON obtenidos tras los distintos procesos a los que son sometidos.

Los directorios en cuestión, siguiendo orden de creación para los JSON de datos son los siguientes:

1. RawData
2. ParsedData
3. RefinedData
4. OldData

Y los de códigos (estación):

1. RawCode
2. ParsedCode
3. RefinedCode (TODO)

4. OldCode (TODO)

El primer nivel es aquel que se obtiene de la llamada con la Spider a la web, devolviendo todos los datos de esta.

El segundo, es obtenido tras ejecutar ya sea `formatear_data_JSONs.py` en caso de querer parsear los datos o `formatear_code_JSONs.py` para los códigos.

El tercero se obtiene tras eliminar la duplicidad de datos en comparación con los ya almacenados en la base de datos mediante la ejecución de `filtrar_data_JSONs.py`.

Finalmente el cuarto es el subproducto obtenido tras la comparación, tomando el fichero original ya formateado y cambiándole de directorio y el nombre de tal forma que se distinga del resto de ficheros.

Posts

Estos Scripts son los encargados de enviar los datos mediante un Post Request al servidor Django.

Diseñados bajo el mismo principio de fomentar la ampliabilidad del proyecto que los Executer, reciben el nombre de la web de la cual deseas enviar los datos a la hora de ejecutarlo junto al comando en forma de argumento.

Cron

Cron es un administrador regular de procesos en segundo plano presente en los sistemas basados en Unix. Con él es posible programar la automatización de ejecución de procesos en intervalos de tiempo, pudiendo indicar el minuto, hora, día, mes e incluso día de la semana.

La especificación de los procesos se realiza en el archivo `crontab` y, su estructuración es la siguiente:

```
.----- minuto (0-59)
| .----- hora (0-23)
| | .----- día del mes (1-31)
| | | .----- mes (1-12) o meses en inglés
| | | | .--- día de la semana (0-6) (domingo=0 o 7) o días en inglés
| | | | |
* * * * * comando a ejecutar
```

En nuestro caso queremos el equivalente a dos instancias de Cron, una que se encargue de obtener los datos ya sea cada quince minutos, media hora y una hora manteniendo la base de datos actualizada para poder realizar las posteriores predicciones y otra que mensualmente compruebe la existencia de nuevas estaciones o el cese del uso de alguna de las ya disponibles.

Así pues, Cron es el encargado de ejecutar cada proceso necesario dentro de la plataforma, ya sea, ejecutar las Spiders, los Scripts de formateo como de filtrado y, el envío de los datos a Django para su inserción en PostGreSQL.

De esta forma dispondríamos de un sistema cerrado automático, el cual nos permitiría trabajar en otros apartados como puede ser la integración de mas webs en la plataforma o la mejora del sistema de predicción.

Django

La instancia del servidor de Django es la encargada de tanto recibir los datos obtenidos como de enviarlos a la base de datos. Finalmente, una vez se dispusiera de la aplicación de predicción se encargaría de pedir los datos almacenados y de enviarlos mediante POST a la aplicación.

PostGreSQL

La base de datos, ejecutada en una maquina virtual independiente, dispone de las siguientes dos tablas:

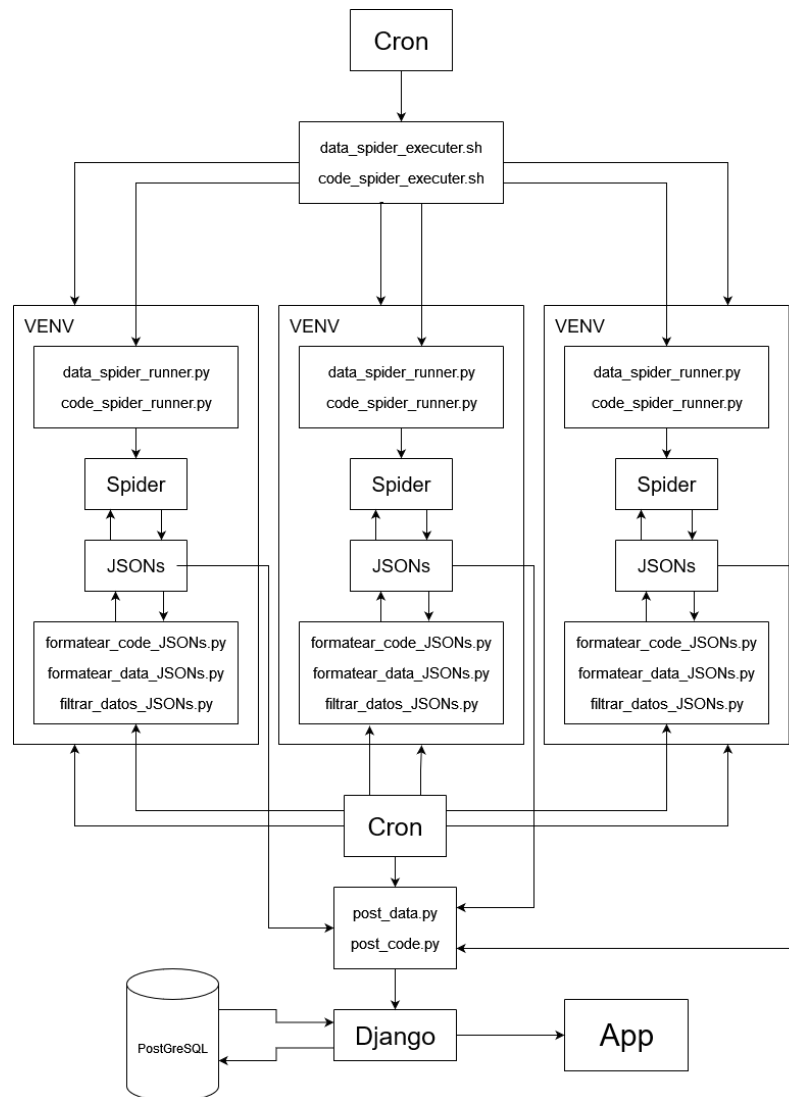


Figura 4.3: Arquitectura de obtención y tratamiento de datos

5.1 Creación de Spiders

Una vez instalado Scrapy, en nuestro directorio escogido escribimos el siguiente comando para generar un nuevo proyecto de Scrapy.

```
scrapy startproject miproyecto
```

Nos creara un nuevo directorio con el siguiente contenido.

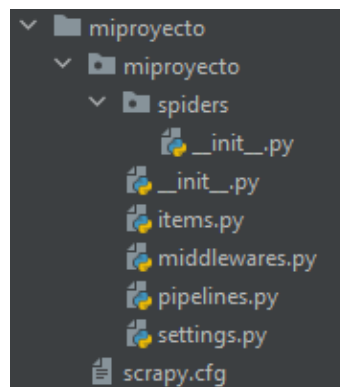


Figura 5.1: Estructura del proyecto recién creado

Primero entraremos en el directorio recientemente creado y luego ejecutaremos el comando encargado de crear la Spider.

```
cd miproyecto  
scrapy genspider mispider webausar.com
```

En caso de no especificar el protocolo usado por la web Scrapy asumirá que usa HTTPS.

Tras ejecutar el comando la Spider habrá sido generada dentro de la carpeta spiders.




Figura 5.2: Directorio de almacenamiento de las Spider

Una vez abierto el archivo vemos que dispone del siguiente código.

```
1  import scrapy
2
3
4  class MispiderSpider(scrapy.Spider):
5      name = "mispider"
6      allowed_domains = ["webausar.com"]
7      start_urls = ["https://webausar.com"]
8
9  def parse(self, response):
10     pass
```

Código 5.1: Spider recién generada


Como podemos ver Scrapy usa una programación orientada a objetos, siendo cada Spider una clase representada dentro del proyecto.

Analizando las variables definidas vemos las siguientes, name, nombre por el que debemos referenciar la Spider a la hora de ejecutarla; allowed_domains, indica que dominios podemos visitar, negando la entrada a cualquier dominio que no este definido en ella, es importante no especificar protocolo, de esta manera funcionara para cualquier web ya sea HTTP como HTTPS que pertenezca a ese dominio, de lo contrario se limitara al protocolo indicado; start_urls, URL inicial sobre la que se hará la request de petición de datos.

El método parse es aquel al que se envía la respuesta obtenida de la web, para realizar el filtrado de la información, quedándote unicamente con la deseada. Este método es invocado automáticamente por la Spider, sin necesidad real de hacerlo tu manualmente.

5.1.1 Proceso de obtención de datos

Para poder realizar es la extracción de los datos, primero debemos ir a la web deseada e inspeccionar su estructuración. Para ello como ejemplo vamos a usar la web de aemet.



Bienvenido

EL TIEMPO SERVICIOS CLIMÁTICOS CONÓCENOS I+D+i CONÓCER MÁS EMPLEO PÚBLICO Y BECAS DATOS ABIERTOS SEDE ELECTRÓNICA

Inicio > El tiempo > Observación > Hoy y últimos días

Hoy y últimos días. Comunidad Foral de Navarra

Datos horarios Resumen viernes 04 Resúmenes diarios anteriores

Mapa de España Mapa **Tabla**

Actualizado: viernes, 04 agosto 2023 a las 11:42 hora oficial
Fecha y hora: viernes, 04 agosto 2023 a las 11:00 hora oficial

[Exportar a excel](#) [Exportar a csv](#)

Estación	Provincia	Temp. (°C)	V. vien. (km/h)	Dir. viento	Racha (km/h)	Dir. racha	Prec. (mm)	Presión (hPa)	Tend. (hPa)	Humedad (%)
Aranguren, Ilundain	Navarra	16.1	10	↘	26	↘	0.0			78.0
Areso	Navarra									
Bardenas Reales, Base Aérea	Navarra	19.0	37	↘	54	↘	0.0	986.2	0.9	56.0
Baztan, Irurita	Navarra	15.6	5	↗	8	↗	1.8			97.0
Bera	Navarra	17.4	3	↗	14	↗	1.0			94.0
Cáceda	Navarra	18.3	17	↘	36	↘	0.0			65.0
Esteribar, Embalse de Eugi	Navarra	13.2					1.4			99.0
Irurtzun	Navarra									
Isaba/Izaba	Navarra	12.4	9	↘	24	↘	0.6			95.0
Larraga	Navarra	18.4	23	↘	49	↘	0.0			62.0
Los Arcos	Navarra									
Monreal/Elo	Navarra	14.1	25	↘	37	↘	0.2			86.0
Monteagudo	Navarra									
Navascués/Nabaskoze	Navarra	15.6					0.0			73.0
Olite/Erriberri	Navarra	17.8	18	↘	37	↘	0.0			63.0
Oroz-Betelu/Orotz-Betelu	Navarra									
Pamplona, Aeropuerto	Navarra	18.5	17	↘	30	↘	0.0	969.2	0.9	66.0
Roncesvalles/Orreaga	Navarra	10.5	6	↗	21	↗	2.0			99.0
Tudela	Navarra	19.7	14	↘	40	↘	0.0			56.0
Valcarlos/Luzaide	Navarra									

Figura 5.3: Web de Aemet para obtención de datos

Una vez encontrada la web deseada, accediendo mediante el F12 a la herramienta de inspección, buscamos el elemento representativo del dato deseado. En nuestro caso queremos obtener tanto el nombre como el código de la estación. Ambos se encuentran en el mismo elemento que forma la primera columna de la tabla.



Figura 5.4: Inspector de webs

Como en este caso es posible filtrar fácilmente los datos, los obtendremos todos directamente, aunque lo más común sería obtener las filas primero para luego iterar por cada una de ellas. Para obtenerlos podemos hacerlo mediante el selector de XPath como con el de CSS.

```
rows = response.xpath('//div[@id="contenedor_tabla"]/table/tbody/tr/td/a')
ó
rows = response.css("div#contenedor_tabla tbody tr a")
```

Esto nos devuelve una lista de objetos tipo Selector, cosa que nos permite conforme vamos iterando por cada elemento volver a usar un selector para filtrar únicamente los datos deseados. En nuestro caso.

```
path = rows[i].xpath("@href").get()
name = rows[i].xpath("./text()").get()
ó
path = rows[i].css("*:attr(href)").get()
name = rows[i].css("*:text").get()
```

De esta forma, mediante el uso de la función `get()`, pasamos de tener un objeto Selector a un String. El uso de `get()` sobre una lista devuelve el primer elemento, en caso de querer transformar toda la lista el método a usar es `getall()`.

Finalmente, como de la URL obtenida,

```
'/es/eltiempo/observacion/ultimosdatos?k=nav&l=9263X&w=0&datos=det&f=precipitacion'
```

solo nos interesa el código de la estación (parámetro `l` de la query), lo filtraremos.

```
code = path.split('&')[1].split('=')[1]
```

5.1.2 Guardado de datos

Scrapy almacena todos los datos en forma de múltiples diccionarios, tantos como webs usadas. Para acceder a esta información Scrapy nos proporciona dos alternativas, el uso de Items junto a ItemLoaders, siendo clases específicas de Scrapy o, mediante la palabra reservada yield de Python, siendo esta la opción elegida debido a su fácil implementación. De esta forma escribiremos.

```
1 yield {  
2     'estacion': name,  
3     'codigo': path.split('&')[1].split('=')[1],  
4 }
```

Código 5.2: Guardar datos

Actualmente si se ejecuta la Spider nos imprimiría los datos obtenidos por pantalla, aunque pueden ser almacenados en un fichero tanto CSV como JSON, a la hora de ejecutar la Spider añadiendo en el comando "-o nombre.csv ó -o nombre.json".

Para un uso ligero de forma manual esa alternativa es más que suficiente, pero en nuestro caso, al querer ejecutarlas de forma automática mediante el uso de Runners, debemos implementar una variable llamada custom_settings para cada una de las Spider. Esta permite, sin la necesidad de modificar el archivo settings.py, añadir configuraciones o dependencias independientes en las Spiders.

```
1 custom_settings = {  
2     'FEEDS': {  
3         'JSONs/RawCode/codigos_aemet.json': {  
4             'format': 'json',  
5             'encoding': 'utf-8',  
6             'overwrite': True,  
7         }  
8     }  
9 }
```

Código 5.3: Configurar guardado en JSON

Con esto indicamos que, en la ruta especificada, nos almacene un fichero JSON utf-8 y, que cada vez que se llame a esta Spider sobre-escriba el fichero anterior.

5.1.3 Spider básica

Una vez obtenemos los datos y los podemos almacenar, ya estaría nuestra Spider básica terminada.

```
1 import scrapy
```

```
2
3
4 class AemetCodeSpider(scrapy.Spider):
5     name = "aemet_code"
6     allowed_domains = ["www.aemet.es"]
7     start_urls = ["https://www.aemet.es/es/eltiempo/observacion/"
8                  "ultimosdatos?k=nav&w=0&datos=det&x=h24&f=precipitacion"]
9     custom_settings = {
10         'FEEDS': {
11             'JSONs/RawCode/codigos_aemet.json': {
12                 'format': 'json',
13                 'encoding': 'utf-8',
14                 'overwrite': True,
15             }
16         }
17     }
18
19 def parse(self, response):
20     rows = response.css("div#contenedor_tabla tbody tr a")
21
22     for row in rows:
23         path = row.xpath("@href").get()
24         name = row.xpath("./text()").get()
25         code = path.split('&')[1].split('=')[1]
26
27         yield {
28             'estacion': name,
29             'codigo': code,
30         }
```

Código 5.4: Spider de ejemplo

5.1.4 Método start_requests()

El método `start_requests()` es llamado de forma automática al iniciar la Spider, siendo el encargado de hacer la llamada a la web indicada en `start_urls` y, una vez obtenidos los datos llamar a la función `parse`, todo mediante un objeto `Request` de Scrapy, el cual devolverá un objeto tipo `HTMLResponse`. En caso de querer alterar el funcionamiento de la Spider este es el método a sobre-escribir.

Como en nuestro caso queremos obtener los datos de todas las estaciones dentro de un mismo dominio, reescribiremos la función para que recorra el JSON con los

códigos de estas y, hacer una llamada por estación con Request. El código quedaría de la siguiente manera.

```
1 def start_requests(self):
2     with open("JSONs/RawCode/codigos_aemet.json", encoding="utf-8") as
3         f:
4         data = json.load(f)
5     for estacion in data:
6         url = f'https://www.aemet.es/es/eltiempo/observacion'
7             "/ultimosdatos?k=nav&l={estacion["codigo"]}&w=0&"
8             "datos=det&x=&f=temperatura'"
9         yield scrapy.Request(url, self.parse)
```

Código 5.5: Sobre-escritura de start_request()

Al definir la función de esta manera no es necesario declarar la variable start_urls, por lo que siempre que necesitemos sobre-escribir la función, no usaremos la variable.

5.1.5 Eliminar Log

Cuando se verifique el correcto funcionamiento de la Spider es recomendable quitar el máximo número de Log por pantalla posible, es por eso que, en el fichero settings.py escribiremos las siguientes líneas.

```
1 LOG_LEVEL = 'WARNING'
2 LOG_ENABLED = False
```

Código 5.6: Configurar LOG

5.2 Spiders usadas

Como se ha dicho anteriormente, para este proyecto se han creado cuatro proyectos de Scrapy, uno por cada web.

5.2.1 Aemet

```
1 import scrapy
2
3
4 class AemetCodeSpider(scrapy.Spider):
5     name = "aemet_code_spider"
6     allowed_domains = ["www.aemet.es"]
```

```

7 start_urls = ["https://www.aemet.es/es/eltiempo/observacion/"
8 "ultimosdatos?k=nav&w=0&datos=det&x=h24&f=temperatura"]
9 custom_settings = {
10     'FEEDS': {
11         'JSONs/RawCode/codigos_aemet.json': {
12             'format': 'json',
13             'encoding': 'utf-8',
14             'overwrite': True,
15         }
16     }
17 }
18
19 def parse(self, response):
20     rows = response.css("div#contenedor_tabla tbody tr a")
21
22     for row in rows:
23         path = row.xpath("@href").get()
24         name = row.xpath("./text()").get()
25         yield {
26             'estacion': name,
27             'codigo': path.split('&')[1].split('=')[1],
28         }

```

Código 5.7: Code Spider

Siendo esta la Spider usada como ejemplo no hay mucho más que comentar al respecto, se dedica a obtener los nombres y códigos de cada estación.

```

1 import json
2
3 import scrapy
4
5
6 class AemetDataSpider(scrapy.Spider):
7     name = "aemet_data_spider"
8     allowed_domains = ["www.aemet.es"]
9     custom_settings = {
10         'FEEDS': {
11             'JSONs/RawData/datos_aemet.json': {
12                 'format': 'json',
13                 'encoding': 'utf-8',
14                 'overwrite': True,
15             }

```

```
16     }
17 }
18
19 def start_requests(self):
20     with open("JSONs/RawCode/codigos_aemet.json", encoding="utf-8") as
21         f:
22         data = json.load(f)
23     for estacion in data:
24         url = f'https://www.aemet.es/es/eltiempo/observacion/"
25             "ultimosdatos?k=nav&l={estacion["codigo"]}&w=0&"
26             "datos=det&x=&f=temperatura'
27         yield scrapy.Request(url, self.parse)
28
29 def parse(self, response):
30     latitud = response.css('abbr.latitude::text').get()
31     longitud = response.css('abbr.longitude::text').get()
32     estacion = response.css("a.separador_pestanhas").get()
33     rows = response.css('tbody tr')
34
35     datos = []
36     for row in rows:
37         dato = {
38             'fecha y hora': row.xpath('./td[1]/text()').get() + ':00',
39             'temperatura (C)': row.xpath('./td[2]/text()').get(),
40             'humedad (%)': row.xpath('./td[10]/text()').get(),
41             'precipitacion (mm)': row.xpath('./td[7]/text()').get(),
42         }
43
44         if dato['precipitacion (mm)'] != " ":
45             datos.append(dato)
46
47     yield {
48         'coordenadas': latitud + ' | ' + longitud,
49         'estacion': estacion.split('=')[3].split('&')[0],
50         'datos': datos,
51     }
```

Código 5.8: Data Spider

Como vemos, la Spider de obtención de datos ya es un poco más compleja, necesitando sobre-escribir la función de `start_request()`. También se puede observar como inicialmente todos los datos son almacenados en una lista antes de ser guardados, el

motivo de esto es muy simple y, es que de no hacerlo solo recibiría el primer dato de entre todos los recogidos.

A su vez dentro del bucle for se ha añadido un if para asegurarse de no guardar datos vacíos, pues puede darse el caso en el que la web aun no tenga el dato de precipitación a cierta hora pero si muestre esta franja horaria pues dispone de otros datos como pueden ser aquellos relacionados con el viento.

Por otro lado, como las coordenadas son mostradas en la misma página que los datos, en vez de crear otra Spider específicamente para obtenerlos, se hace uso de esta con el fin de minimizar código y tiempo de ejecución.

5.2.2 Chcantabrico

```
1  import scrapy
2
3
4  class ChcantabricoCodeSpider(scrapy.Spider):
5      name = "chcantabrico_code_spider"
6      allowed_domains = ["www.chcantabrico.es"]
7      start_urls = ["https://www.chcantabrico.es/nivel-de-los-rios"]
8      custom_settings = {
9          'FEEDS': {
10              'JSONs/RawCode/codigos_chcantabrico.json': {
11                  'format': 'json',
12                  'encoding': 'utf-8',
13                  'overwrite': True,
14              }
15          }
16      }
17
18  def parse(self, response):
19      rows = response.xpath('//table[@class="tablefixedheader
20                             niveles"]/tbody/tr')
21
22      for row in rows:
23          codigoBusqueda = row.css('td.codigo::text').get()
24          limites = row.css('table.umbrales_gr td.datos::text').getall()
25          paths = row.xpath('./td/a/@href').getall()
26          estaciones = row.xpath('./td/a/text()').getall()
27
28          for i in range(len(limites)):
29              if limites[i] == 'No definido':
```



```
29         limites[i] = None
30
31     yield {
32         'estacion': estaciones[-3],
33         'codigo': paths[-1].split("=")[-1],
34         'codigoSecundario': codigoBusqueda,
35         'seguimiento': limites[0],
36         'prealerta': limites[1],
37         'alerta': limites[2],
38     }
```

Código 5.9: Code Spider

Esta puede ser la Spider de obtención de códigos más compleja. esto se debe en parte por la estructuración de la web, mostrando una tabla con otra tabla integrada por cada una de las filas, como por la cantidad de información que dispone.

El primer problema fue como obtener las filas de la tabla principal, pues en muchos de los intentos realizados no solo tomaba estas filas, si no que tomaba aquellas que formaban parte de las tablas incluidas es ellas también. Finalmente, aunque con el Selector CSS no lo logré, mediante Xpath fue posible filtrarlas.

Otra cosa a mencionar es que Chcantabrico proporciona dos códigos por estación, uno referenciando a la estación en si, siendo el usado para posteriormente obtener las coordenadas, aquel que llamo codigoSecundario o codigoBusqueda mientras que, el segundo hace referencia a los datos como tal. Puesto que no todas las filas disponen de la misma cantidad de enlaces, se obtienen todos sabiendo que siempre el ultimo de ellos dispone del código deseado.

Finalmente, dentro de la tabla secundaria, esta es la única web que llega a proporcionar los valores de seguimiento, pre-alerta y alerta del río, siendo estos una buena base para empezar con las predicciones de inundación. En caso de no estar definido el valor simplemente se indicará como None.

```
1  import io
2  import json
3
4  import pandas as pd
5  import scrapy
6
7
8  class ChcantabricoNivelSpider(scrapy.Spider):
9      name = "chcantabrico_nivel_spider"
10     allowed_domains = ["www.chcantabrico.es"]
11     custom_settings = {
12         'FEEDS': {
```

```

13         'JSONs/RawData/datos_nivel_chcantabrico.json': {
14             'format': 'json',
15             'encoding': 'utf-8',
16             'overwrite': True,
17         }
18     }
19 }
20
21 def start_requests(self):
22     with open("JSONs/RawCode/codigos_chcantabrico.json",
23             encoding="utf-8") as f:
24         data = json.load(f)
25     for estacion in data:
26         params_nivel = {
27             'p_p_id': 'GraficaEstacion_INSTANCE_wH0LL6jTUysu',
28             'p_p_lifecycle': '2',
29             'p_p_state': 'normal',
30             'p_p_mode': 'view',
31             'p_p_resource_id': 'downloadCsv',
32             'p_p_cacheability': 'cacheLevelPage',
33             '_GraficaEstacion_INSTANCE_wH0LL6jTUysu_cod_estacion':
34                 f'{estacion["codigo"]}',
35             '_GraficaEstacion_INSTANCE_wH0LL6jTUysu_tipodato': 'nivel',
36         }
37         url = 'https://www.chcantabrico.es/evolucion-de-niveles'
38         yield scrapy.FormRequest(url=url,
39                                 method='GET',
40                                 formdata=params_nivel,
41                                 callback=self.parse,
42                                 cb_kwargs={'estacion': estacion['codigo']})
43
44 def parse(self, response, estacion):
45     if not response.text.startswith('-'):
46         urlData = response.text
47         rawData = pd.read_csv(io.StringIO(urlData), delimiter=';',
48                               encoding='utf-8', header=1)
49         rawData.columns = ['fecha y hora', 'nivel (m)']
50         parsedData = rawData.to_json(orient="records")
51
52     yield {

```

```
51         'estacion': estacion,  
52         'datos': json.loads(parsedData)  
53     }
```

Código 5.10: Nivel Spider

```
1  import io  
2  import json  
3  
4  import pandas as pd  
5  import scrapy  
6  
7  
8  class ChcantabricoPluvioSpider(scrapy.Spider):  
9      name = "chcantabrico_pluvio_spider"  
10     allowed_domains = ["www.chcantabrico.es"]  
11     custom_settings = {  
12         'FEEDS': {  
13             'JSONs/RawData/datos_pluvio_chcantabrico.json': {  
14                 'format': 'json',  
15                 'encoding': 'utf-8',  
16                 'overwrite': True,  
17             }  
18         }  
19     }  
20  
21     def start_requests(self):  
22         with open("JSONs/RawCode/codigos_chcantabrico.json",  
23                 encoding="utf-8") as f:  
24             data = json.load(f)  
25             for estacion in data:  
26                 params_pluvio = {  
27                     'p_p_id': 'GraficaEstacion_INSTANCE_ND81Xo17PIZ7',  
28                     'p_p_lifecycle': '2',  
29                     'p_p_state': 'normal',  
30                     'p_p_mode': 'view',  
31                     'p_p_resource_id': 'downloadCsvPluvio',  
32                     'p_p_cacheability': 'cacheLevelPage',  
33                     '_GraficaEstacion_INSTANCE_ND81Xo17PIZ7_cod_estacion':  
34                         f'{estacion["codigo"]}',  
35                     '_GraficaEstacion_INSTANCE_ND81Xo17PIZ7_tipodato': 'pluvio',  
36                 }
```

```

35     url = 'https://www.chcantabrico.es/precipitacion-acumulada'
36     yield scrapy.FormRequest(url=url,
37                               method='GET',
38                               formdata=params_pluvio,
39                               callback=self.parse,
40                               cb_kwargs={'estacion': estacion['codigo']})
41
42
43 def parse(self, response, estacion):
44     if not response.text.startswith('-'):
45         urlData = response.text
46         rawData = pd.read_csv(io.StringIO(urlData), delimiter=';',
47                                encoding='utf-8', header=1)
48         rawData.columns = ['fecha y hora', 'nivel (m)']
49         parsedData = rawData.to_json(orient="records")
50
51         yield {
52             'estacion': estacion,
53             'datos': json.loads(parsedData)
54         }

```

Código 5.11: Pluviometric Spider

Chacantabrico muestra datos tanto del nivel del río como de la precipitación, aunque lo hace en dos direcciones distintas, haciendo necesario el uso de dos Spiders.

A su vez, como Chcantabrico no muestra los datos por pantalla, incluyendo un botón sobre el que pulsar para obtenerlos descargando un fichero CSV, en vez de hacer una request básica mediante la clase Request, vamos a hacer uso de FormRequest para hacer una llamada GET, pudiendo simular la llamada a un formulario y obtener los datos que este devuelve. De esta forma, pasándole los parámetros necesarios en el argumento formdata a la URL indicada, podemos obtener los datos sin la necesidad de ningún CSV, simulando en cierto modo una llamada mediante cURL. Cabe mencionar que, Request devuelve un HTMLResponse y que, la respuesta que obtenemos de estas llamadas no es código HTML, por lo que, aun en caso de que llegue a ser posible usar Request, es más correcto el uso de FormRequest devolviendo un FormResponse para este tipo de casos.

El uso del argumento cb_kwargs sirve para enviar un mayor número de argumentos a la función parse() de los que normalmente recibe, es por ello que la función parse() recibe un tercer argumento que hemos decidido llamar estacion. En este caso para poder enviar a cada conjunto de datos recibidos el código de la estación a la que pertenecen, pues dentro de la respuesta obtenida solo se proporciona el nombre de esta.

Dentro de la función `parse()` lo primero que se hace es comprobar que realmente se ha recibido una respuesta correcta, pues, aunque todas las estaciones disponen de datos del nivel del río, no todas disponen los de precipitación, el problema viene cuando a estas estaciones se les piden los datos, ya que en vez de enviar un error 404 como sería esperado, te devuelven una respuesta vacía iniciada por '-'. Una alternativa para deshacerse de esta comprobación sería eliminando aquellas estaciones que no proporcionen datos o filtrándolas para no hacer la llamada directamente, aunque esto no solo nos resultaría más complejo, si no que nos crearía el problema de que cada cierto tiempo habría que comprobar si alguna estación ha empezado a proporcionar datos para incluirla nuevamente en la lista de estaciones a las cuales hacer llamada.

Conclusiones y Trabajo Futuro

Referencias

- [1] C. Dierbach, "Python as a first programming language," *Journal of Computing Sciences in Colleges*, vol. 29, no. 3, pp. 73–73, 2014.
- [2] "Python 3.11.3 Documentation general python faq." <https://docs.python.org/3/faq/general.html>. Accessed: 2023-04-07.
- [3] L. E. Borges, *Python para desenvolvedores: aborda Python 3.3*. Novatec Editora, 2014.
- [4] M. F. Krafft, *The Debian system: concepts and techniques*. No Starch Press, 2005.
- [5] R. Hertzog and R. Mas, *The Debian Administrator's Handbook: Debian Jessie From Discovery To Mastery*. Freexian, 2015.
- [6] "Debian Project Documentation a brief history of debian." <https://www.debian.org/doc/manuals/project-history/index.en.html>. Accessed: 2023-04-12.
- [7] "Debian Project Documentation our philosophy: Why we do it and how we do it." <https://www.debian.org/intro/philosophy.en.html>. Accessed: 2023-04-12.
- [8] R. P. Pollei, *Debian 7: System Administration Best Practices*. Packt Publishing, 2013.
- [9] "Debian Project Documentation what does free mean?." <https://www.debian.org/intro/free.en.html>. Accessed: 2023-04-12.
- [10] "GNU About Free Software Documentation what is free software?." <https://www.gnu.org/philosophy/free-sw.en.html>. Accessed: 2023-04-12.

- [11] “Debian Project Documentation debian social contract version 1.2 ratified on october 1st, 2022..” https://www.debian.org/social_contract.en.html. Accessed: 2023-04-12.
- [12] “Debian Project Documentation what is the partners program?.” <https://www.debian.org/partners/index.en.html>. Accessed: 2023-04-12.
- [13] “Debian Project Documentation how to donate to the debian project.” <https://www.debian.org/donations.en.html>. Accessed: 2023-04-12.
- [14] “Debian Project Documentation reasons to use debian.” https://www.debian.org/intro/why_debian.en.html. Accessed: 2023-04-12.
- [15] D. Ghimire, “Comparative study on python web frameworks: Flask and django,” 2020.
- [16] “Python Documentation web frameworks for python.” <https://wiki.python.org/moin/WebFrameworks>. Accessed: 2023-04-12.
- [17] D. Glez-Peña, A. Lourenço, H. López-Fernández, M. Reboiro-Jato, and F. Fdez-Riverola, “Web scraping technologies in an api world,” *Briefings in bioinformatics*, vol. 15, no. 5, pp. 788–797, 2014.
- [18] “Django Documentation design philosophies.” <https://docs.djangoproject.com/en/3.0/misc/design-philosophies/>. Accessed: 2023-04-12.
- [19] M. Alchin, *Pro Django*. Apress, 2013.
- [20] A. Ravindran, *Django Design Patterns and Best Practices*. Packt Publishing Ltd, 2015.
- [21] B. Zhao, “Web scraping,” *Encyclopedia of big data*, pp. 1–3, 2017.
- [22] V. Krotov and L. Silva, “Legality and ethics of web scraping,” 2018.
- [23] H. Yang, “Design and implementation of data acquisition system based on scrapy technology,” in *2019 2nd International Conference on Safety Produce Informatization (IICSPI)*, pp. 417–420, IEEE, 2019.

Glosario

parabras, 1

SATA, 1


```
1 public void mostrarTodasNotas(){
2     int a = 1;
3     System.out.println("Estas son todas las notas que hay
4         guardadas.");
5     for(int j=0; j<lista_notas.size(); j++){
6         System.out.print(a+"-");
7         System.out.println(lista_notas.get(j).toString());
8         a++;
9     }
```

Código A1: Mostrar notas.